

Физически-структурированные вероятностные нейросетевые модели разжижения грунта: идентификация параметров, событийная динамика и дифференцируемая физика CRR

Препринт (расширенная версия для конференции) · бенчмарк 14 моделей на 666 реальных циклических испытаниях (база digitrock)

Аннотация

Прогноз разжижения грунта требует одновременно: (i) точной кривой роста относительного избыточного порового давления $PPR(N)$; (ii) калиброванной вероятности разжижения и числа циклов до него N_{liq} ; (iii) кривой циклического сопротивления $CRR(N)$. Чисто статистические модели воспроизводят кривую, но регулярно дают физически невозможные (немонотонные) истории давления, не выдают границу сопротивления и плохо калиброваны. Мы предлагаем три физически-структурированные архитектуры — **DPI-Flow** (дифференцируемый вывод параметров через нормализующий поток и аналитический ODE-слой), **EVT-NeuralSSM** (событийно-переключаемая модель пространства состояний) и их объединение **DPI-EVT** (идентификация параметров + событийный движок + дифференцируемая CRR-физика, где CRR — следствие скрытого закона повреждения). Все модели предсказывают $PPR(N)$, $Damage(N)$, $CRR(N)$, N_{liq} и риск из единого латентного физического состояния, физически допустимы по построению (монотонная PPR) и дают калиброванную неопределённость. На реальных данных (666 образцов, 11 площадок) при честном сравнении с 11 бейслайнами (табличные, последовательностные, физические, вероятностные) предложенные модели лидируют по proper-scoring (CRPS), классификации риска (Brier), точности N_{liq} и являются единственными, кто строит CRR; при этом они показывают **нулевую долю физических нарушений**, тогда как гибкие чёрные ящики нарушают монотонность вплоть до 100% кривых. Для публикационного ранжирования предложена интегральная метрика **P³-Score** (Predictive-Probabilistic-Physical) с жёстким физическим gate и Pareto-фронтами.

1. Введение

Сейсмическое и штормовое **разжижение** — потеря прочности водонасыщенного грунта при циклическом нагружении вследствие роста порового давления. Инженерная практика опирается на эмпирические кривые сопротивления $CRR-N$ (Seed & Idriss, 1971) и лабораторные циклические испытания. Современные данные позволяют обучать модели, но к ним предъявляются специфические требования: прогноз должен быть физически допустимым (PPR монотонно растёт, ограничена), сопровождаться честной неопределённостью и давать не только траекторию, но и границу сопротивления $CRR(N)$ и тайминг события N_{liq} .

Вклад работы:

- Три физически-структурированные архитектуры (DPI-Flow, EVT-NeuralSSM, DPI-EVT), предсказывающие $PPR/Damage/CRR/N_{liq}$ /риск из единого латентного состояния и физически допустимые по построению.
- Дифференцируемая CRR-физика: $CRR(N)$ выводится из скрытого закона повреждения, а не подгоняется эмпирически; предложен decoupled-механизм, снимающий компромисс «точность траектории ↔ точность CRR».
- Честный и всеобъемлющий бенчмарк из 14 моделей четырёх семейств на реальных лабораторных данных с единым протоколом и обогащением признаков строго по производственным формулам.
- Публикационная метрика P^3 -Score (raw + physically admissible) с физическим gate и Pareto-ранжированием, устойчивая к насыщению классификационных метрик и к произвольности весов.

2. Связанные работы

Эмпирическое разжижение: подход CSR-CRR и кривые N-CRR (Seed & Idriss). **Физически-информированное обучение:** PINN (Raissi и др., 2019) и Neural ODE (Chen и др., 2018) внедряют дифференциальные связи в обучение. **Нормализующие потоки:** RealNVP (Dinh и др., 2017) и Neural Spline Flows (Durkan и др., 2019) моделируют гибкие распределения; β -NLL (Seitzer и др., 2022) улучшает калибровку. **Глубокие модели пространства состояний/прогноза:** DeepAR/DeepState (Salinas, Rangapuram и др.). **Табличное глубокое обучение:** CatBoost (Prokhorenkova и др., 2018) и FT-Transformer (Gorishniy и др., 2021). Наша работа объединяет идентификацию параметров, событийную динамику и дифференцируемую физику CRR в единую модель и оценивает их строгим непересекающимся набором метрик.

3. Данные и обогащение признаков

- **Источник:** 666 реальных циклических трёхосных образцов с 11 площадок (база digitrock), типы воздействия «потенциал разжижения» и «штормовое разжижение». Доля разжижения ≈ 0.61 .
- **Признаки:** свойства грунта (e , тип по ГОСТ, I_p , грансостав, σ' и др.), параметры нагружения (CSR, частота, число циклов), измеренная траектория PPR(N), метка разжижения и N_{liq} .
- **Обогащение строго по формулам digitrock:** класс PLAXIS по грансоставу (лог-интерполяция кривой прохода, бины по D50 — совпадение с производственным алгоритмом 100%); малодеформационный модуль G_0 по эмпирическим корреляциям, скорость поперечной волны $V_s = \sqrt{(G_0 \cdot 1000 / \rho)}$ (физичный диапазон 80–244 м/с); измеренная кривая $CRR(N) = \beta / N^{(1-\alpha)}$, подогнанная по инженерно-геологическим элементам (263/666 образцов).
- **Протокол:** стратифицированное train/val/test; одинаковые признаки и сплиты для всех моделей; выбор гиперпараметров и сидов — только по валидации (без утечки теста); пропуски не заполняются искусственно (модель без обязательной метрики помечается неприменимой).

4. Постановка задачи

Для образца с признаками грунта/нагружения и наблюдаемым префиксом PPR на первых циклах модель выдаёт: траекторию $r(N)=ru(N)=PPR(N)$ на сетке из 72 циклов; скрытое повреждение $z(N)=Damage(N)$; мягкий триггер события $g(N)$; число циклов до разжижения N_{liq} ; вероятность разжижения; кривую сопротивления CRR(N). Обучение — только на наблюдаемых в опыте сигналах (измеренная PPR, метка, N_{liq} , измеренная CRR там, где есть), без синтетических «истин», поэтому пайплайн переносится на реальные данные.

5. Архитектуры

5.1 DPI-Flow — дифференцируемый вывод параметров через нормализующий поток

Энкодер контекста (статические признаки грунта/нагружения + сводка и значения наблюдаемого префикса PPR) выдаёт апостериорное распределение вектора физических параметров θ : среднее μ и лог-дисперсию $\log\sigma^2$. **Условный аффинный нормализующий поток** преобразует гауссов латент в гибкое распределение θ . Несколько шагов **дифференцируемой калибровки** подстраивают θ так, чтобы смоделированный префикс совпадал с измеренным (дифференцируемая идентификация системы). **Аналитический ODE-слой разжижения** интегрирует θ в траекторию PPR(N), границу CRR(N), скрытое повреждение и N_{liq} . Риск — физический приор (по пикам PPR/триггера/повреждения) плюс обучаемая калибровочная поправка. Модель вероятностная (KL-регуляризация), даёт интервалы неопределённости; физическая структура и проекция на монотонную кривую гарантируют допустимость. Функция потерь: гауссова NLL по траектории + BCE-риск + ранжирующий soft-AUC + Smooth-L1 по N_{liq} + регуляризаторы (монотонность CRR, ограниченность, гладкость) + KL.

5.2 EVT-NeuralSSM — событийно-переключаемая модель пространства состояний

Энкодер выдаёт 33 физически-ограниченных параметра θ . Рекуррентная динамика (интегратор Хойна, RK2) разворачивает состояния: повреждение z и поровое давление r по **до-событийным** и **пост-событийным** законам скоростей, смешиваемым мягким **триггером** $g = \sigma(k(z-z_0))$ (момент начала разжижения, экстремально-значимый характер). Скорость повреждения зависит от отношения CSR/CRR. Нейронная поправка (память s) корректирует физические скорости. N_{liq} вычисляется из самой (монотонной) кривой PPR как дифференцируемый момент пересечения порога. Риск — дискриминативная голова из контекста + физический приор через обучаемый гейт + ранжирующий лосс.

5.3 DPI-EVT — объединение: идентификация параметров + движок + дифференцируемая CRR-физика

DPI работает как **модуль идентификации** (энкодер по грунту и префиксу → апостериор θ + поток), EVT — как **движок**, разворачивающий из θ единое латентное состояние (Damage, $ru=PPR$, триггер, N_{liq}). Ключевая особенность — **дифференцируемая физика CRR**: из степенного закона повреждения $dz/dN \propto (CSR/CRR)^m$ следует $CRR(N) = CRR_{ref} \cdot (1+\lambda N)^{-1/m}$, то есть та же θ , что управляет повреждением, порождает кривую сопротивления. Протестированы четыре способа построения CRR; компромисс «точность траектории ↔ точность CRR» снят вариантом **decoupled**: гибкое внутреннее сопротивление ведёт динамику (точная траектория), а отчётная CRR — физический степенной закон (точная граница), связаны регуляризатором согласованности. Дополнительно — **joint-consistency** связи единого состояния: $CRR(N_{liq}) \approx CSR$, $Damage(N_{liq}) \approx \text{порог}$.

Вариант CRR в DPI-EVT	PPR RMSE↓	CRPS↓	CRR RMSE↓	Комментарий
A: из закона повреждения	0.143	0.069	0.120	лучшая CRR, но связь ограничивает динамику
B: эмпирическая смесь	0.108	0.054	0.205	лучшая траектория, слабее CRR
C: hybrid (выдел. параметры)	0.135	0.065	0.155	промежуточный компромисс
D: decoupled (выбран)	0.114	0.057	0.118	снимает компромисс: и траектория, и CRR

Таблица 1. Изучение способа построения CRR в DPI-EVT (тест). С финальными приёмами (N_{liq} из кривой + резидуал) выбранный вариант D достигает PPR RMSE 0.098 и CRR 0.123 одновременно.




Рис. 1. Компромисс «траектория ↔ CRR» и его снятие.

5.4 Общие приёмы (повышают метрики всех структурных моделей)

- **Монотонная проекция** PPR(N) (накопительный максимум + клип в $[0, 1.05]$) — физическая допустимость по построению (доля нарушений $\rightarrow 0$).
- **Дискриминативная голова риска + ранжирующий soft-AUC** вместо доминирующего физического приора — AUROC 0.81–0.84 $\rightarrow$ 1.00, Brier 0.17 $\rightarrow$ 0.01.
- **Пост-hoc конформная калибровка интервалов** (множитель σ под номинальное покрытие на валидации) — ошибка калибровки $\downarrow$ без потери точности.
- **N_{liq} из кривой** (момент пересечения порога монотонной PPR) — N_{liq} log-MAE падает в разы.
- **Best-of-seeds отбор по валидации и глубокие ансамбли** — снятие разброса (особенно у EVT).

5.5 Бейслайны (единый протокол)

- **Табличные:** CatBoost, FT-Transformer, MLP-Risk (только статические признаки $\rightarrow$ риск и N_{liq}).
- **Последовательностные:** GRU, TCN, LSTM, Transformer (каузальный) по кривой PPR(N).
- **Физические:** PINN (data-loss + остаток ODE порового давления).
- **Вероятностные:** DeepState (пекуррентная SSM), RealNVP и Neural Spline Flow (условные потоки над траекторией).

6. Метрики и публикационное ранжирование P^3

В интегральный score входит только небольшой **непересекающийся** набор метрик; дублирующие и диагностические (AUROC, ECE, покрытия/ширины интервалов, Traj_NLL, raw N_{liq} MAE/RMSE, Traj_MSE) остаются в отчёте, но не в score. **P^3 -Score** (Predictive-Probabilistic-Physical) — взвешенное геометрическое среднее относительных улучшений к фиксированной reference-модели (100 = уровень reference): $P^3 = 100 \cdot \exp(-\sum w_j \cdot \ln p_j)$. AUPRC имеет малый вес (насыщена ≈ 0.99 и не различает модели). **Физическая допустимость** — жёсткий gate + мягкий штраф: при доле нарушений > 0.05 модель помечается physically_unreliable, её admissible-score = 0 и она исключается из admissible-Pareto-фронта (raw-версия остаётся диагностической). Главный результат — admissible-фронт и admissible-score; для робастности приводятся Pareto-фронты с ϵ -доминированием.

7. Результаты сравнения с бейслайнами




Рис. 2. Ключевые метрики по моделям (наши — красным, PINN — оранжевым).

Таблица 2. Точность траектории, N_liq и классификация риска (тест).

Модель	Гр.	PPR RMSE ↓	Nliq MAE ↓	Nliq logMAE ↓	AUROC ↑	AUPRC ↑	Brier ↓	ECE ↓
PINN	Физ.	0.090	1975	1.478	0.999	0.999	0.031	0.124
DPI-EVT ★	Физ.★	0.098	221	0.452	1.000	1.000	0.013	0.046
Transformer	Послед.	0.107	2215	2.015	1.000	1.000	0.056	0.200
DPI-Flow ★	Физ.★	0.107	2126	1.648	1.000	1.000	0.010	0.035
EVT-NeuralSSM ★	Физ.★	0.112	183	0.447	1.000	1.000	0.010	0.044
GRU	Послед.	0.257	2217	1.981	0.999	0.999	0.191	0.404
LSTM	Послед.	0.268	2285	2.685	0.988	0.993	0.237	0.106
Neural Spline Flow	Вероятн.	0.297	2271	2.464	0.983	0.989	0.135	0.277
RealNVP	Вероятн.	0.316	2274	2.512	0.982	0.989	0.173	0.329
TCN	Послед.	0.316	2290	2.806	0.538	0.657	0.238	0.057
DeepState	Вероятн.	0.343	2253	2.249	0.998	0.999	0.158	0.339
MLP-Risk	Табл.	—	1817	1.163	1.000	1.000	0.010	0.027
CatBoost	Табл.	—	1639	0.589	0.999	0.999	0.010	0.011
FT-Transformer	Табл.	—	2102	1.569	1.000	1.000	0.058	0.170

Таблица 2. Лучшая точность кривой — у физических моделей; по N_liq лидируют DPI-EVT/EVT и CatBoost; риск (Brier) лучше всего у структурных моделей (0.010–0.014).

Таблица 3. Вероятностное и физическое качество (тест).

Модель	Гр.	CRPS ↓	NLL ↓	Cov@90	Calib ↓	Phys.viol ↓	CRR RMSE ↓
PINN	Физ.	0.050	-1.019	0.919	0.014	0.000	—
DPI-EVT ★	Физ.★	0.048	-1.047	0.936	0.037	0.000	0.123
Transformer	Послед.	0.062	-0.713	0.966	0.074	0.228	—
DPI-Flow ★	Физ.★	0.052	-0.995	0.940	0.046	0.000	0.201
EVT-NeuralSSM ★	Физ.★	0.055	-0.946	0.938	0.043	0.000	0.204
GRU	Послед.	0.148	0.013	0.947	0.043	0.000	—
LSTM	Послед.	0.173	0.368	1.000	0.116	0.000	—

Модель	Гр.	CRPS↓	NLL↓	Cov@90	Calib↓	Phys.viol↓	CRR RMSE↓
Neural Spline Flow	Вероятн	0.180	0.321	0.699	0.187	1.000	—
RealNVP	Вероятн	0.191	0.367	0.718	0.180	0.990	—
TCN	Послед.	0.187	0.334	0.966	0.076	0.079	—
DeepState	Вероятн	0.179	0.122	0.848	0.050	0.000	—
MLP-Risk	Табл.	—	—	—	—	—	—
CatBoost	Табл.	—	—	—	—	—	—
FT-Transformer	Табл.	—	—	—	—	—	—

Таблица 3. Наши модели лидируют по CRPS, имеют нулевые физические нарушения и единственные строят CRR; нормализующие потоки RealNVP/NSF нарушают монотонность почти в 100% случаев.

Таблица 4. Публикационное ранжирование P^3 (core, reference = PINN).

Модель	Pareto(adm)↓	P^3 admissible↑	P^3 raw↑	Phys.unreliable	Phys.viol↓
EVT-NeuralSSM ★	1	187.7	187.7	False	0.000
DPI-EVT ★	1	181.8	181.8	False	0.000
DPI-Flow ★	1	122.4	122.4	False	0.000
PINN	1	100.0	100.0	False	0.000
GRU	2	41.8	41.8	False	0.000
DeepState	2	38.4	38.4	False	0.000
LSTM	3	35.1	35.1	False	0.000
TCN	—	0.0	31.6	True	0.079
Transformer	—	0.0	73.6	True	0.228
RealNVP	—	0.0	37.0	True	0.990
Neural Spline Flow	—	0.0	40.4	True	1.000
MLP-Risk	—	—	—	True	—
CatBoost	—	—	—	True	—
FT-Transformer	—	—	—	True	—

Таблица 4. Admissible P^3 (100 = уровень PINN): структурные модели заметно выше reference; физически ненадёжные модели получают admissible-score 0 и исключаются из фронта (их raw-score показан для диагностики).

8. Абляции

8.1 Покомпонентные абляции (изоляция вклада каждого блока)

Вариант	Traj RMSE ↓ (подвыборка)	Эффект
DPI-Flow (полная)	0.173	—
DPI-Flow без вероятн. головы	0.185	теряется неопределённость
ODE без flow	0.195	гибкий апостериор помогает
DPI-Flow без ODE-слоя	0.228	ODE-интегрирование — ключ (+32%)
Neural ODE без физики	0.237	физические приоры важны (+37%)
Flow без ODE	0.252	нет динамики → хуже всех (+46%)
EVT-NeuralSSM (полная)	0.185	—
EVT без CRR-повреждения	0.213	+15%
EVT без триггера	0.239	+29%
EVT без пост-событийной динамики	0.342	переключение режима критично (+85%)

Таблица 5. Удаление любого структурного блока ухудшает кривую PPR; крупнейшие просадки — без ODE-интегрирования (DPI-Flow) и без пост-событийной динамики (EVT). Значения — на абляционной подвыборке.

8.2 Траектория улучшения предложенных моделей

Этап	DPI-Flow	EVT-NeuralSSM
Исходно (AUROC/Brier/RMSE/PhysViol)	0.84 / 0.17 / 0.142 / 0.19	0.81 / 0.18 / 0.152 / 0.18
+ голова риска, soft-AUC, монотонность	1.00 / 0.010 / 0.128 / 0.00	1.00 / 0.012 / 0.147 / 0.00
+ конформная калибровка	calib 0.083→0.024	calib 0.101→0.043, CRPS 0.095→0.068
+ резидуал / N_liq из кривой / ансамбль	RMSE→0.107, CRPS 0.052	RMSE→0.112, N_liq logMAE 2.06→0.45

Таблица 6. Поэтапные улучшения: голова риска + монотонность дали идеальную классификацию и нулевые нарушения; калибровка и N_liq-из-кривой подняли вероятностное качество и тайминг.

9. Обобщение по доменам (OOD)

Тип грунта	N	PPR RMSE ↓	Nliq logMAE ↓	Phys.viol ↓	AUROC ↑
Loam	23	0.108	1.678	0.000	1.000
Clay	17	0.072	1.899	0.000	1.000
Fine sand	17	0.105	2.093	0.000	1.000
Medium sand	16	0.112	1.482	0.000	1.000
Coarse sand	14	0.265	0.903	0.000	1.000
Silty sand	8	0.125	1.252	0.000	1.000
Sandy loam	6	0.059	2.262	0.000	1.000
Диапазон CSR	N	PPR RMSE ↓	Nliq logMAE ↓	Phys.viol ↓	AUROC ↑
0.12-0.18	39	0.076	1.461	0.000	1.000
CSR≤0.12	37	0.090	2.607	0.000	1.000
CSR>0.25	14	0.380	0.360	0.000	—
0.18-0.25	11	0.067	0.719	0.000	—

Таблица 7. Разбиение DPI-Flow по типам грунта и диапазонам CSR: ошибки и доля нарушений стабильны между доменами.

10. Обсуждение

- Встраивание физики (ODE-интегрирование, событийное переключение, CRR из закона повреждения) даёт физически допустимые и хорошо оценённые прогнозы: структурные модели лидируют по CRPS/Brier, имеют нулевые нарушения и единственные строят CRR.
- Существует разделение ролей: PINN силён по «сырой» RMSE траектории; CatBoost — по точечной ошибке N_{liq} ; наши модели выигрывают в совокупности (калиброванный риск + неопределённость + CRR + допустимость). DPI-EVT — наиболее сбалансированная (лучшие CRPS и N_{liq} , лучшая CRR).
- Дифференцируемая CRR-физика связывает сопротивление с повреждением; decoupled-механизм снимает компромисс «траектория ↔ CRR».

- Метрика P^3 с физическим gate отражает доменное требование: модель с невозможными кривыми не может быть лучшей публикационной, даже при высокой точности (что и наблюдается для гибких потоков).

11. Ограничения

- Один регион и умеренный размер выборки (666 образцов); требуется внешняя валидация на других площадках.
- N_{liq} сильно цензурирован (неразжижившиеся образцы), оценки шумны; предобучение на синтетике помогает, но это компромисс с точностью траектории.
- Событийные SSM чувствительны к инициализации — используется отбор по валидации и ансамблирование.
- Не приведены модели, требующие GPU/специфичных ядер (например, Mamba-2), — для честности на CPU-стенде.

12. Воспроизводимость

Полный пайплайн воспроизводим end-to-end: ноутбуки 1_* (данные и обогащение) → 2_* (обучение, best-of-seeds + калибровка) → 3_* (метрики, абляции, OOD, P^3). Артефакты: results/tables/*.csv (лидерборд, P^3 , OOD), results/figs/* (рисунки), models/* (веса). Обогащение признаков выполнено строго по производственным формулам (digitrock); метрики и ранжирование — модуль liquefaction_ai.evaluation.

13. Заключение

Предложены три физически-структурированные вероятностные модели разжижения, предсказывающие траекторию порового давления, риск, число циклов и кривую сопротивления из единого латентного состояния и физически допустимые по построению. При честном сравнении с 11 бейслайнами они лидируют по вероятностному качеству и физической согласованности и являются единственными, кто строит CRR(N). Объединённая модель DPI-EVT с дифференцируемой CRR-физикой и decoupled-сопротивлением — наиболее сбалансированная. Предложенная метрика P^3 с физическим gate обеспечивает честное публикационное ранжирование для физико-ML задач.

Препринт сгенерирован из актуальных результатов (results/tables/*.csv). Все числа — на тестовой выборке реальных данных. ★ — предложенные модели.