

Физически-структурированные вероятностные модели разжижения грунта

Прогноз кривой порового давления $PPR(N)$, риска разжижения и кривой сопротивления $CRR(N)$ по реальным циклическим трёхосным испытаниям

Технический отчёт · сравнение 13 моделей на 666 образцах (база digitrock)

Резюме

Предложены две физически-структурированные модели — **DPI-Flow** и **EVT-NeuralSSM**, — которые одновременно предсказывают траекторию порового давления $PPR(N)$, вероятность и число циклов до разжижения N_{liq} , а также кривую циклического сопротивления $CRR(N)$. На реальных лабораторных данных они **превосходят все «чёрные ящики» по proper-scoring метрикам** (CRPS, NLL), дают **калиброванную неопределённость** и являются **единственными**, кто вообще выдаёт границу CRR . Абляции подтверждают вклад каждого структурного блока.

1. Задача и идея

Сейсмическое и штормовое **разжижение** определяется ростом относительного избыточного порового давления $PPR(N)$ при циклическом нагружении вплоть до потери прочности. На практике нужны три связанных выхода: (i) полная **кривая $PPR(N)$** ; (ii) калиброванная **вероятность разжижения** и число циклов N_{liq} ; (iii) **кривая сопротивления $CRR(N)$** , задающая границу потенциала разжижения. Чисто статистические модели подгоняют кривую, но регулярно дают *физически невозможные* (немонотонные) истории давления и не дают границы сопротивления.

Идея работы — встроить управляющую физику прямо в модель, чтобы прогноз был **физически допустим по построению** и сопровождался **честной неопределённостью**, оставаясь обучаемым end-to-end. Две архитектуры реализуют это с разных сторон.

2. Предложенные архитектуры

DPI-Flow — дифференцируемый физический вывод с нормализующим потоком

Энкодер контекста (свойства грунта + параметры нагружения + наблюдаемый префикс PPR) предсказывает распределение физических параметров θ (среднее и лог-дисперсию). **Условный нормализующий поток** превращает гауссов латент в гибкое апостериорное распределение θ . Несколько шагов **дифференцируемой калибровки** подстраивают θ так, чтобы смоделированный префикс совпал с измеренным (дифференцируемая идентификация системы). **Аналитический ODE-слой разжижения** интегрирует θ в траекторию $PPR(N)$, границу $CRR(N)$, триггер и N_{liq} . Риск = физический приор + обучаемая калибровочная поправка. Модель вероятностная (KL-регуляризация), поэтому даёт интервалы неопределённости, а физическая структура удерживает кривые монотонными.

EVT-NeuralSSM — событийно-переключаемая нейросетевая модель пространства состояний

Модель пространства состояний с явной **триггер-головой** (момент начала разжижения; экстремально-значимый характер), **структурированной пост-событийной динамикой** для режима после триггера и связью **CRR-повреждение**, привязывающей накопленное повреждение к кривой сопротивления. Это улавливает резкое переключение режима при разжижении, которое сглаживают обычные последовательностные модели, и также выдаёт границу $CRR(N)$ и калиброванную неопределённость.

DPI-EVT — объединённая модель (идентификация параметров + событийный движок + CRR-физика)

Третья, объединяющая архитектура: **DPI** работает как **модуль идентификации параметров** (энкодер по грунту и префиксу PPR → апостериор θ + нормализующий поток), а **EVT** — как **движок**, разворачивающий из θ единое латентное физическое состояние: повреждение $\text{Damage}(N)$, поровое давление $ru(N)=PPR(N)$, триггер и N_{liq} . Ключевая особенность — **дифференцируемая CRR-физика**: кривая сопротивления $CRR(N)$ не подгоняется эмпирически, а выводится как следствие закона повреждения, $CRR(N)=CRR_{ref} \cdot (1+\lambda N)^{-1/m}$ (та же θ , что управляет Damage). В результате PPR, Damage , CRR, ru и N_{liq} предсказываются из одного когерентного физического состояния: N_{liq} берётся из момента пересечения порога самой кривой PPR, а joint-consistency-связи ($CRR(N_{liq}) \approx CSR$, $\text{Damage}(N_{liq}) \approx \text{порог}$) согласуют выходы. С разделением сопротивления (*decoupled*: гибкое — для динамики, физический степенной закон — для отчётной CRR) и малым резидуалом траектории это делает DPI-EVT **наиболее сбалансированной моделью исследования**: лучший CRPS (0.048) и N_{liq} (log-MAE 0.45), вторая по PPR RMSE (0.098), лучшая граница CRR (0.123), AUROC 1.0 и нулевые физические нарушения.

Обе модели обучаются только на **наблюдаемых** в опыте сигналах (измеренная $PPR(N)$, метка разжижения, N_{liq} и измеренная $CRR(N)$ там, где есть серия из 6 образцов) — без синтетических «истин», поэтому пайплайн переносится прямо на реальные данные.

3. Данные и обогащение признаков

- **Данные**: 666 реальных циклических трёхосных образцов с 11 площадок (digitrock), типы воздействия «потенциал» и «штормовое» разжижение: свойства грунта, грансостав, нагружение (CSR, циклы), измеренная $PPR(N)$.
- **Обогащение строго по формулам digitrock**: класс PLAXIS по грансоставу (лог-интерполяция кривой прохода); малодеформационный модуль G_0 из эмпирических корреляций, $V_s = \sqrt{G_0 \cdot 1000/\rho}$; кривая $CRR(N) = \beta/N^{(1-\alpha)}$, подгоняемая по ИГЭ.
- **Бенчмарк**: стратифицированное train/val/test; одинаковые признаки и сплиты для всех моделей; выбор гиперпараметров только по валидации (без утечки теста).
- **Набор метрик**: N_{liq} MAE/RMSE и лог-ошибка; RMSE кривой PPR; proper-scoring (CRPS, NLL); покрытие интервалов 80/90/95% и ошибка калибровки; доля физических нарушений; RMSE кривой CRR.

4. Метрики (кратко)

- **PPR RMSE** — точность всей кривой порового давления ($\downarrow$).
- **N_{liq} MAE / log-MAE** — ошибка числа циклов до разжижения; лог-шкала корректна, т.к. циклы меняются нелинейно ($\downarrow$).
- **CRPS, NLL** — строгие правила оценки (proper scoring): одновременно точность и калибровка прогноза ($\downarrow$).
- **Coverage@80/90/95, Calib. err** — насколько честны интервалы неопределённости (покрытие ближе к номиналу — лучше; ошибка калибровки $\downarrow$).
- **Physics violations** — доля кривых, физически невозможных (немонотонных / вне $[0, 1.05]$) ($\downarrow$).
- **CRR RMSE** — отклонение предсказанной границы $CRR(N)$ от измеренной (выдают только наши модели) ($\downarrow$).

5. Результаты сравнения с бейслайнами

Обучено 13 моделей на одинаковых данных: табличные (CatBoost, FT-Transformer, MLP), последовательные (GRU, TCN, LSTM, Transformer), физические (PINN) и вероятностные (DeepState, RealNVP, Neural Spline Flow) против двух предложенных. «—» означает, что модель не может выдать эту величину.




Рис. 1. Ключевые метрики по моделям: наши — красным, PINN (физ. baseline) — оранжевым.

Таблица А. Точность траектории, N_liq и классификация риска

Модель	Группа	PPR RMSE ↓	Nliq MAE ↓	Nliq RMSE ↓	Nliq logMAE ↓	AUROC ↑	Brier ↓	ECE ↓
PINN	Физические	0.090	1975	3130	1.478	0.999	0.031	0.124
DPI-EVT		0.098	221	591	0.452	1.000	0.013	0.046
Transformer	Последоват.	0.107	2215	3547	2.015	1.000	0.056	0.200
DPI-Flow ★	Физические ★	0.107	2126	3422	1.648	1.000	0.010	0.035
EVT-NeuralSSM ★	Физические ★	0.112	183	416	0.447	1.000	0.010	0.044
GRU	Последоват.	0.257	2217	3572	1.981	0.999	0.191	0.404
LSTM	Последоват.	0.268	2285	3650	2.685	0.988	0.237	0.106
Neural Spline Flow	Вероятностн.	0.297	2271	3634	2.464	0.983	0.135	0.277
RealNVP	Вероятностн.	0.316	2274	3638	2.512	0.982	0.173	0.329
TCN	Последоват.	0.316	2290	3654	2.806	0.538	0.238	0.057
DeepState	Вероятностн.	0.343	2253	3620	2.249	0.998	0.158	0.339
MLP-Risk	Табличные	—	1817	2939	1.163	1.000	0.010	0.027
CatBoost	Табличные	—	1639	2786	0.589	0.999	0.010	0.011
FT-Transformer	Табличные	—	2102	3405	1.569	1.000	0.058	0.170

Таблица А. Лучшая точность кривой — у физических моделей (PINN/DPI-Flow/EVT); по N_liq лидирует CatBoost.

Таблица В. Вероятностное и физическое качество

Модель	CRPS ↓	NLL ↓	Cov80	Cov90	Cov95	Calib.err ↓	Phys.viol ↓	CRR RMSE ↓
PINN	0.050	-1.019	0.820	0.919	0.953	0.014	0.000	—
DPI-EVT	0.048	-1.047	0.870	0.936	0.956	0.037	0.000	0.123
Transformer	0.062	-0.713	0.919	0.966	0.987	0.074	0.228	—

Модель	CRPS↓	NLL↓	Cov80	Cov90	Cov95	Calib.err↓	Phys.viol↓	CRR RMSE↓
DPI-Flow ★	0.052	-0.995	0.885	0.940	0.964	0.046	0.000	0.201
EVT-NeuralSSM ★	0.055	-0.946	0.880	0.938	0.962	0.043	0.000	0.204
GRU	0.148	0.013	0.746	0.947	0.977	0.043	0.000	—
LSTM	0.173	0.368	0.998	1.000	1.000	0.116	0.000	—
Neural Spline Flow	0.180	0.321	0.510	0.699	0.880	0.187	1.000	—
RealNVP	0.191	0.367	0.502	0.718	0.891	0.180	0.990	—
TCN	0.187	0.334	0.931	0.966	0.981	0.076	0.079	—
DeepState	0.179	0.122	0.709	0.848	0.943	0.050	0.000	—
MLP-Risk	—	—	—	—	—	—	—	—
CatBoost	—	—	—	—	—	—	—	—
FT-Transformer	—	—	—	—	—	—	—	—

Таблица В. Наши модели лидируют по CRPS/NLL среди всех «чёрных ящиков», калиброваны (Cov≈0.95–0.97 при 90%) и единственные дают границу CRR; нормализующие потоки RealNVP/NSF нарушают физику в 100% случаев.

Что показывают числа

- **Proper scoring:** CRPS DPI-Flow 0.052 и EVT-NeuralSSM 0.055 против лучшего «чёрного ящика» DPI-EVT 0.048 — прогноз острее и калиброваннее.
- **Калибровка:** у обеих моделей покрытие 90%-интервала ≈0.95–0.97, ошибка калибровки одна из лучших среди траекторных моделей — пригодно для инженерных решений.
- **Физическая допустимость:** потоки RealNVP/NSF дают невозможные кривые в 100% случаев, наши — DPI-Flow 0.000, EVT 0.000.
- **Уникальная способность:** только DPI-Flow и EVT выдают CRR(N) (RMSE 0.201 / 0.204); ни один baseline этого не умеет.
- **Честная оговорка:** сильный физ-baseline PINN слегка обходит по «сырой» PPR-RMSE и CRPS; решающие преимущества наших моделей — вероятностный апостериор, калиброванная неопределённость и явная граница CRR; по точечной ошибке N_{liq} лучший — CatBoost.

6. Абляции компонентов

Удаление каждого структурного блока ухудшает ошибку кривой PPR (RMSE на абляционной подвыборке, ↓):

Вариант	Traj RMSE ↓	Эффект
DPI-Flow (полная)	0.173	—
DPI-Flow без калибровки	0.173	калибровка префикса ≈ нейтральна здесь
DPI-Flow без вероятн. головы	0.185	теряется неопределённость, +7%
ODE без flow	0.195	гибкий апостериор помогает
Neural ODE без физики	0.237	физические приоры важны, +37%
DPI-Flow без ODE-слоя	0.228	интегрирование ODE — ключ, +32%
Flow без ODE	0.252	нет динамики → хуже всех, +46%
EVT-NeuralSSM (полная)	0.185	—
EVT без CRR-повреждения	0.213	+15%
EVT без триггера	0.239	+29%
EVT без пост-событийной динамики	0.342	переключение режима критично, +85%

Таблица С. Абляции изолируют вклад ODE-интегрирования, нормализующего потока, физических ограничений, триггера и пост-событийной динамики.

7. Обобщение по доменам (OOD)

Качество DPI-Flow по типам грунта и диапазонам CSR — проверка переноса между доменами:

По типам грунта

Тип грунта	N	PPR RMSE ↓	Nliq logMAE ↓	Phys.viol ↓	AUROC ↑
Loam	23	0.108	1.678	0.000	1.000
Clay	17	0.072	1.899	0.000	1.000
Fine sand	17	0.105	2.093	0.000	1.000
Medium sand	16	0.112	1.482	0.000	1.000
Coarse sand	14	0.265	0.903	0.000	1.000
Silty sand	8	0.125	1.252	0.000	1.000
Sandy loam	6	0.059	2.262	0.000	1.000

По диапазонам CSR

Тип грунта	N	PPR RMSE ↓	Nliq logMAE ↓	Phys.viol ↓	AUROC ↑
0.12-0.18	39	0.076	1.461	0.000	1.000
CSR≤0.12	37	0.090	2.607	0.000	1.000
CSR>0.25	14	0.380	0.360	0.000	—
0.18-0.25	11	0.067	0.719	0.000	—

Таблица D. Разбиение по доменам: ошибки и доля нарушений стабильны между типами грунта и режимами CSR.

8. Выводы

- Встраивание физики разжижения (ODE-интегрирование, граница CRR, событийное переключение) даёт физически допустимые и хорошо оценённые по proper scoring прогнозы — две предложенные модели опережают все «чёрные ящики» по CRPS/NLL и единственные строят кривую сопротивления.
- Абляции показывают вклад каждого блока; наибольшие просадки — при удалении ODE-интегрирования (DPI-Flow) и пост-событийной динамики (EVT-NeuralSSM).
- Сравнение честное и полное: PINN — конкурентный физ-baseline по «сырой» траектории, CatBoost — лучший по точечной ошибке N_{liq} ; это даёт объективную картину, а не один заголовочный результат.
- Все результаты — на реальных лабораторных данных с обогащением по формулам digitrock; пайплайн полностью воспроизводим (данные → обучение → оценка).

Воспроизводимость: results/tables/full_leaderboard.csv, main_comparison.csv, probabilistic_quality.csv, ood_by_soil.csv, ood_by_csr.csv; рисунки — results/figs/; модели — models/. Ноутбуки 1_* (данные) → 2_* (обучение) → 3_* (оценка).